

Сопоставление деклараций и регуляций ТН ВЭД

Data Scientist

Тестовое задание на ранжирование регуляций по тексту таможенной декларации

Задача

Для каждой таможенной декларации верните десять наиболее подходящих регуляций в порядке убывания релевантности. Выбор метода остаётся за вами. В README.md опишите принятый подход, рассмотренные альтернативы, допущения и основные компромиссы.

Ожидаемый объём работы — 4-6 часов. Если какое-либо условие не определено, сделайте разумное допущение и явно зафиксируйте его.

Данные

Все входные файлы находятся в каталоге `./data`:

declarations.jsonl	120 деклараций: служебные поля, описание товара, расширенное описание. Целевой код отсутствует.
regulations.jsonl	360 регуляций: <code>regulation_id</code> , десятизначный <code>code</code> , <code>description</code> , <code>notes</code> , <code>explanation</code> .
tnved_knowledge.txt	Дополнительный контекст по ТН ВЭД: структура справочника, примечания и пояснения.

Запуск и результат

Среда подготавливается заранее: установка зависимостей и получение необходимых моделей не входит в лимит запуска. Само решение запускается без сети локально на CPU и/или GPU из корня проекта. Разрешается использование локальной GPU и моделей размером не более 8 миллиардов параметров:

```
python run.py --data ./data --out ./out
```

Лимит запуска — 30 минут и 8 ГБ оперативной памяти; видеопамять локальной GPU в этот лимит не входит. Все необходимые во время запуска зависимости, модели и другие файлы должны быть зафиксированы или поставляться воспроизводимо.

Обязательный файл `out/predictions.csv`: колонки `declaration_id`, `rank`, `regulation_id`, `score`. Для каждой декларации должно быть ровно 10 уникальных регуляций с рангами 1-10. `score` — конечное число; большее значение означает более высокую релевантность.

Оценка

Для каждой декларации в скрытой разметке указана одна релевантная регуляция. **Hit@k** — доля деклараций, для которых она находится среди первых k результатов. **MRR@10** — среднее обратное место релевантной регуляции в top-10.

Метрика	Hit@1	Hit@5	Hit@10	MRR@10
Минимальный результат	0,30	0,68	0,80	0,45

Минимумы задают проходной уровень; более высокие значения учитываются при сравнении решений. Формат должен быть корректен для 100% деклараций. Отсутствующие строки, неизвестные ID, повторные регуляции и повторные ранги считаются ошибкой формата.

Что сдать

- исходный код и README.md с установкой, командами запуска, описанием подхода и зафиксированными версиями;
- полученный `out/predictions.csv`;
- краткий разбор пяти ошибок или сомнительных примеров: почему система выбрала эти результаты и что можно улучшить;
- воспроизводимое решение без ручного кодирования скрытых соответствий и без сетевых запросов во время оценки.

Оцениваются качество поиска, обоснованность решений, воспроизводимость, анализ ошибок и понимание собственного подхода.